

动手学四足机器人

从动力学建模到强化学习部署

潘为 Wei Pan

Newcastle University 正教授 | 智身科技 CTO

配套课程：深蓝学院

配套代码： <https://github.com/zsibot>

2026 年 6 月 5 日

目录

第一章 导论：四足控制的演进	9
1.1 引言	10
1.2 历史脉络：现代控制范式	10
1.2.1 MPC 与凸优化	10
1.2.2 强化学习	11
1.3 MPC 的数学结构与能力边界	11
1.3.1 浮动基座刚体动力学	11
1.3.2 MPC 的优化形式	12
1.3.3 模型敏感性	12
1.3.4 实时性约束与 SRBD 近似	13
1.3.5 接触模式预设	13
1.4 统一视角：通过梯度优化做控制	13
1.4.1 可微物理仿真的形式化	14
1.4.2 主定理：三种梯度，同一引擎	14
1.4.3 MPC 与 RL 的统一	15
1.4.4 本章核心命题的解答	15
1.5 仿真引擎生态与选型	16
1.5.1 可微与不可微：两类技术路线	16
1.5.2 选型决策流程	17
1.5.3 本书为什么选 MJX	17
1.5.4 代码示例：可微辨识	18
1.6 实验平台：智身钢镚 (xg)	18
1.6.1 从 URDF 读到的真实参数	19
1.6.2 URDF 缺陷的量化严重性	19
1.7 本章小结	20
第 1 章习题	20
第二章 机器人建模：URDF 与浮动基座动力学	23
2.1 引言	24
2.2 旋转表示与浮动基座坐标	24
2.2.1 三维旋转：SO(3) 与四元数	24
2.2.2 角速度与四元数微分	25
2.2.3 浮动基座的广义坐标 $\mathbf{q}$	25
2.2.4 浮动基座的广义速度 $\dot{\mathbf{q}}$	26

2.3	正向运动学	27
2.3.1	运动链的拓扑	27
2.3.2	链式 FK 公式	27
2.3.3	xg 单腿足端位置	27
2.4	几何雅可比矩阵	28
2.4.1	从位置到速度	28
2.4.2	接触雅可比的构造	28
2.4.3	解析、数值与自动微分雅可比	29
2.5	浮动基座刚体动力学	29
2.5.1	动能与势能	29
2.5.2	欧拉-拉格朗日方程	30
2.5.3	$\mathbf{M}, \mathbf{C}, \mathbf{g}$ 的物理意义	30
2.5.4	接触力项的几何含义	31
2.5.5	动力学算法: CRBA、RNEA、ABA	31
2.6	URDF 与 MJCF 字段解析	32
2.6.1	URDF 与 MJCF: 两套描述同一对象	32
2.6.2	核心字段	32
2.6.3	xg 模型字段的批判性走查	33
2.7	本章小结	34
	第 2 章习题	35
第三章	模型精度与系统辨识	37
3.1	引言	38
3.2	URDF 参数精度评估	38
3.2.1	三类字段重访	38
3.2.2	辨识范围的工程权衡	39
3.2.3	未辨识字段的处理	39
3.3	摩擦模型与转子惯量	40
3.3.1	谐波减速器的摩擦构成	40
3.3.2	转子惯量的物理	40
3.3.3	$\text{sgn}(\cdot)$ 的不可微问题	40
3.3.4	ϕ 的工程化定义	41
3.4	经典辨识: 线性回归与最小二乘	41
3.4.1	线性回归形式	41
3.4.2	多时刻数据的最小二乘	42
3.4.3	代码实现	42
3.4.4	经典方法的三个工程局限	43
3.5	持续激励与轨迹设计	44
3.5.1	核心条件	44

3.5.2	激励轨迹与 PE 条件	44
3.6	可微辨识：通过仿真器反向传播	44
3.6.1	把仿真器看作 ϕ 的函数	44
3.6.2	损失函数与梯度	45
3.6.3	Adam 优化与收敛诊断	45
3.6.4	经典 vs 可微方法对比	47
3.6.5	辨识误差分析	48
3.7	完整 pipeline 与 Project 2 预告	48
3.7.1	xg 摩擦辨识完整 pipeline	48
3.7.2	Project 2: xg 摩擦辨识	48
3.7.3	与第 6 章的衔接	49
第 3 章习题		49
第四章	强化学习与运动控制	51
4.1	引言	52
4.2	RL 形式化与 locomotion 的特性	52
4.2.1	MDP 重述	52
4.2.2	locomotion 任务的 Markov 性问题	52
4.2.3	与 定理 1.1 (iii) 的精确对应	53
4.3	观测空间与动作空间设计	53
4.3.1	观测空间: proprioception 的具体选择	53
4.3.2	动作空间: 为何不是关节力矩?	54
4.4	奖励函数设计	55
4.4.1	核心奖励的 6 项构成	55
4.4.2	Trot 步态约束	56
4.4.3	奖励权重的工程量级	56
4.5	PPO 算法	56
4.5.1	重要性采样与替代目标	57
4.5.2	截断重要性采样	57
4.5.3	优势函数估计: GAE	57
4.5.4	完整的 PPO 损失	57
4.5.5	网络架构	58
4.5.6	完整的 PPO 训练循环	58
4.6	大规模并行训练: MJX vs Isaac Gym	59
4.6.1	两条路线的设计差异	60
4.6.2	xg 训练的吞吐量对比	60
4.6.3	选型建议 (对接 第 1.5 节)	60
4.7	训练实战与失败模式诊断	61
4.7.1	训练曲线读法	61

4.7.2	常见失败模式与处方	61
4.7.3	Trot 步态调参经验	62
4.8	APG: 可微策略梯度 (半节)	62
4.8.1	解析梯度的推导	62
4.8.2	APG vs PPO 的工程对比	63
4.8.3	APG 在 MJX 中的最小实现	63
4.9	完整 pipeline 与 Project 3 预告	64
4.9.1	xg locomotion 训练完整 pipeline	64
4.9.2	Project 3: xg trot 训练	64
4.9.3	与第 5 章的衔接	65
	第 4 章习题	65
	第五章 强化学习与运动控制 (下): 鲁棒性扩展	67
5.1	引言	68
5.2	域随机化	68
5.2.1	数学形式: 从单点到期望	69
5.2.2	DR 范围矩阵	69
5.2.3	DR 的代码实现	70
5.2.4	DR 范围的权衡	71
5.3	辨识值 $\rightarrow$ DR 中心	72
5.3.1	无辨识: DR 必须保守宽	72
5.3.2	有辨识: DR 中心精准、范围紧	72
5.3.3	对照实验	73
5.3.4	为何辨识让 DR 收紧而性能上升	73
5.3.5	进一步思考: 辨识精度如何影响 DR 范围	74
5.4	课程学习	74
5.4.1	阶段渐进的课程	74
5.4.2	自适应课程	75
5.4.3	Curriculum 与 DR 的关系	76
5.5	地形生成	76
5.5.1	高度场表示	76
5.5.2	四种基础地形	76
5.5.3	地形生成代码	77
5.5.4	地形随机化的设计原则	78
5.6	教师-学生方法 (半节)	78
5.6.1	为何需要教师-学生	78
5.6.2	两阶段训练流程	79
5.6.3	Student 的网络结构	79
5.6.4	蒸馏代码	79

5.6.5 部署	80
5.7 完整 pipeline 与 Project 4 预告	80
5.7.1 多地形多扰动训练完整 pipeline	80
5.7.2 Project 4: xg 在多地形 + DR 下 trot	81
5.7.3 与第 6 章的衔接	81
第 5 章习题	81
第六章 Sim-to-Real 迁移	83
6.1 引言	84
6.2 sim-to-real gap 的系统性分解	84
6.2.1 数学化分解	84
6.2.2 每类 gap 的工程对策	85
6.2.3 与主定理的对应	86
6.3 模型校准: 摩擦前馈与动力学补偿	87
6.3.1 摩擦前馈的工程实现	87
6.3.2 PD 增益的实机标定	87
6.3.3 部署代码示范	88
6.3.4 与第五章 DR 的协同	88
6.4 教师-学生: sim $\rightarrow$ real 蒸馏	89
6.4.1 两种教师-学生的区别	89
6.4.2 Sim $\rightarrow$ Real 蒸馏的训练流程	89
6.4.3 RMA Phase 2: 在线适应	89
6.4.4 Sim $\rightarrow$ Real 蒸馏代码示范	90
6.5 在线辨识与策略适应	91
6.5.1 在线辨识: 轻量化递归方法	91
6.5.2 策略适应: 参数 $\rightarrow$ 策略修正	92
6.5.3 在线辨识的代码示范	92
6.5.4 兑现主定理三种用法的协同	93
6.6 安全性	94
6.6.1 硬件级保护	94
6.6.2 软件级保护	94
6.6.3 状态级保护: 跌倒检测	95
6.6.4 安全监控与日志	95
6.6.5 安全完整性的工程要点	95
6.7 完整 pipeline 与 Project 3 预告	96
6.7.1 Sim-to-Real 部署完整 pipeline	96
6.7.2 Project 3: 策略部署与摩擦补偿	96
6.7.3 与第 7、8 章的衔接	97
第 6 章习题	97

Chapter 3

模型精度与系统辨识

The simulator is only as good as the parameters you put into it.

本章目标

兑现 定理 1.1 (i): 把 式 (2.17) 中定义的待辨识参数 ϕ 从实机数据中辨识出来。建立从经典最小二乘到可微梯度方法的完整工程链路；演示前者的工程局限与后者的优势。

学完你应当能

- 评估 URDF 各字段的可信度
- 建立谐波减速器的摩擦模型
- 推导线性回归形式 $\tau = \mathbf{W}\phi$
- 写出可微辨识的损失函数与梯度
- 完成 Project 2 (xg 摩擦辨识)

本章结构

§3.1	引言：从 $\phi \in \mathbb{R}^{36}$ 到能跑的代码	兑现 定理 1.1 (i)
§3.2	URDF 参数精度评估	接 第一章 表 1.3
§3.3	摩擦模型与转子惯量	谐波减速器物理；不可微项的处理
§3.4	经典辨识：线性回归 + 最小二乘	$\tau = \mathbf{W}(\mathbf{q}, \dot{\mathbf{q}}, \ddot{\mathbf{q}}) \phi$
§3.5	持续激励与轨迹设计	数据采集策略
§3.6	可微辨识：通过仿真器反向传播	jax.grad 与 Adam 优化
§3.7	完整 pipeline + Project 2 预告	经典 vs 可微对比

§3.1 引言

第一章 给出主定理 定理 1.1：在可微物理仿真的框架下，系统辨识、轨迹优化、策略训练共享同一条反向传播链路。第二章 给出待辨识参数集合

$$\phi = \{b_i, f_{c,i}, I_{r,i}\}_{i=1}^{n_a} \in \mathbb{R}^{3n_a}, \quad (3.1)$$

对 x_g 而言 $\phi \in \mathbb{R}^{36}$ 。本章把 定理 1.1 (i) 落地：从一段实机数据出发，通过梯度下降找到最佳 $\hat{\phi}$ ，使得仿真器在 $\hat{\phi}$ 下重现实测数据。

本章命题. 系统辨识不是一道“配齐 URDF 缺失字段”的工程琐事，而是把 式 (2.17) 中三类参数的不确定性转化为一个梯度优化问题。可微物理仿真把这一优化问题的复杂度降到与单次仿真同阶，从根本上简化辨识工程。

本章不止给出辨识算法，更要回答：辨识什么、不辨识什么、为什么这样选。第 3.2 节 评估 URDF 各字段的可信度，为辨识范围划界。第 3.3 节 建立摩擦与转子惯量的工程化模型，并处理 $\text{sgn}(\cdot)$ 在零速度处的不可微问题。第 3.4 节 推导经典线性回归方法，作为可微方法的参照。第 3.5 节 简要讨论数据采集——辨识精度的上限不仅由算法决定，也由数据决定。第 3.6 节 给出可微辨识的完整公式与代码。第 3.7 节 给出 Project 2 与第 6 章 sim-to-real 的衔接。

记号约定. 沿用前两章。本章额外约定：上标 $(\cdot)^{\text{real}}$ 表示来自实机数据的量， $(\cdot)^{\text{sim}}$ 表示仿真器在参数 ϕ 下输出的量。 $\hat{\phi}$ 表示辨识结果， ϕ^* 表示真实参数。

§3.2 URDF 参数精度评估

辨识的第一步不是写优化代码，而是判断 URDF 中哪些字段需要辨识、哪些不必。盲目辨识全部参数会浪费数据维度，并可能因变量过多导致欠定问题。

3.2.1 三类字段重访

第一章的表 1.3 与第二章的表 2.1 已将 x_g 的 URDF 字段分为三类。从辨识的角度，这一分类直接决定了变量集合 ϕ 的构造原则。

字段类别	是否辨识	原因
可信字段		
质量 m_ℓ	不辨识	CAD 给出, 精度 $< 1\%$; 引入只会增加优化变量噪声
连杆几何		同上
关节限位		机械设计文档; 硬约束而非物理参数
有偏差字段		
惯量张量 $\mathbf{I}_\ell$	视情况	CAD 估计偏差约 5–10%; 若 trot 数据足以激发, 可辨识
质心位置 $\mathbf{c}_\ell$	视情况	同上
缺失字段（必须辨识）		
关节阻尼 b_i	必辨	URDF=0; 与 $\dot{\theta}_i$ 线性, 辨识难度低
库仑摩擦 $f_{c,i}$	必辨	URDF=0; 非线性 sgn 项; 辨识难度中
转子惯量 $I_{r,i}$	必辨	URDF=0; 与 $\ddot{\theta}_i$ 挂钩, 需要丰富激励

表 3.1: xg 的 URDF 字段辨识范围。本章主线辨识下方三项 (24 维主目标 + 12 维进阶)。

3.2.2 辨识范围的工程权衡

表 3.1 给出原则性分类。具体到本章 Project, 进一步将范围分为三档:

- **基础 (必做)**. 仅辨识 $\{b_i\}_{i=1}^{n_a}$, $n_a = 12$ 维。黏滞阻尼是 $\dot{\theta}_i$ 的线性函数, 正常 trot 数据足以激发。
- **标准 (推荐)**. 辨识 $\{b_i, f_{c,i}\}_{i=1}^{n_a}$, 24 维。引入库仑摩擦 $f_{c,i} \text{sgn}(\dot{\theta}_i)$ 后需处理 sgn 在零速度处的不可微, 详见第 3.3 节。
- **进阶 (stretch)**. 加上 $\{I_{r,i}\}$, 36 维。涉及 $\ddot{\theta}_i$ 项, 对加速度估计精度敏感, 对激励轨迹要求高。

本章正文以**标准档**为主线展开。

3.2.3 未辨识字段的处理

CAD 给出的可信字段 (质量、几何、限位) 直接信任。有偏差字段 (惯量、质心) 若不在 ϕ 中, 其偏差会以未建模动态形式进入辨识残差, 进而影响 $\hat{\phi}$ 的精度。这一现象的定量分析见

第3.6节末尾的误差讨论。在本章范围内，假设惯量与质心的CAD估计是足够的。

§3.3 摩擦模型与转子惯量

3.3.1 谐波减速器的摩擦构成

谐波减速器（Harmonic Drive）是四足腿部驱动的主流方案：电机经减速器输出到关节，减速比 $N \sim 10\text{--}50$ 。其摩擦由三部分构成：

- **黏滞摩擦**： $\tau_{\text{visc},i} = b_i \dot{\theta}_i$ ，与速度成正比，源自润滑剂剪切。
- **库仑摩擦**： $\tau_{\text{coul},i} = f_{c,i} \text{sgn}(\dot{\theta}_i)$ ，与速度方向相关、量值恒定，源自齿面接触。
- **Stribeck 效应**：低速段摩擦呈非线性下降，源自润滑膜从边界状态到流体状态的过渡。

完整模型为

$$\tau_{\text{fric},i}(\dot{\theta}_i) = b_i \dot{\theta}_i + f_{c,i} \text{sgn}(\dot{\theta}_i) + \tau_{\text{srib},i}(\dot{\theta}_i). \quad (3.2)$$

注记 3.1: 为何本课不辨识 Stribeck 项

Stribeck 项主要影响低速段 ($|\dot{\theta}| < 0.1 \text{ rad/s}$)。四足在 trot 步态下大部分时间速度远高于此阈值，Stribeck 项贡献小于 1%。引入会显著增加优化变量与非线性程度，得不偿失。本课在式 (2.17) 中省略此项；如学生项目对低速精度要求高，可作为习题扩展。

3.3.2 转子惯量的物理

电机转子的转动惯量 $I_{r,\text{motor}}$ 经减速器折算到关节侧时按减速比平方放大：

$$I_{r,\text{eff}} = N^2 I_{r,\text{motor}}. \quad (3.3)$$

xg 的膝关节减速比 $N \approx 7.75$ ，电机转子惯量 $I_{r,\text{motor}} \sim 5 \times 10^{-5} \text{ kg}\cdot\text{m}^2$ ，折算后 $I_{r,\text{eff}} \sim 3 \times 10^{-3} \text{ kg}\cdot\text{m}^2$ ，与小腿连杆本身惯量同量级。完全忽略将导致 $\mathbf{M}$ 系统性偏小。

折算转子惯量进入式 (2.15) 的方式：在 $\mathbf{M}(\mathbf{q})$ 的对角块上加 $\text{diag}(I_{r,\text{eff}})$ 。这一项与 $\mathbf{q}$ 无关，在辨识中作为常数参数处理。

3.3.3 $\text{sgn}(\cdot)$ 的不可微问题

库仑摩擦项 $f_{c,i} \text{sgn}(\dot{\theta}_i)$ 在 $\dot{\theta}_i = 0$ 处不可微。对经典最小二乘方法（第3.4节）影响有限——只要数据点不恰好在 $\dot{\theta}_i = 0$ ，回归矩阵 $\mathbf{W}$ 仍可装配。但对可微方法（第3.6节），自动微分需要梯度信号，必须光滑化。

工程做法是将 sgn 替换为光滑近似：

$$\text{sgn}(\dot{\theta}_i) \approx \tanh(k \dot{\theta}_i), \quad (3.4)$$

其中 $k > 0$ 是过渡陡度参数，典型值 $k = 50\text{--}200$ 。 k 越大越接近真 sgn ，但梯度在 $\dot{\theta}_i = 0$ 附近越尖锐，优化稳定性下降。 k 的选择是工程权衡，本课取 $k = 100$ 。

注记 3.2: 光滑化对辨识结果的影响

将 sgn 替换为 $\tanh(k \cdot)$ 引入了模型偏差。但在 $|\dot{\theta}| > 1/k$ 范围内偏差小于 1%，对 trot 步态典型速度 ($|\dot{\theta}| \sim 5\text{--}20 \text{ rad/s}$) 几乎无影响。第 3.6 节的辨识结果会验证此点： $\hat{f}_c$ 的辨识误差与 $\tanh$ 近似引入的偏差同阶（约 2%），主导误差来自数据噪声而非模型形式。

3.3.4 ϕ 的工程化定义

汇总以上讨论，本章主线下 ϕ 的最终形式为：

定义 3.1: xg 的待辨识参数集合

xg 的 12 个驱动关节，其待辨识参数定义为

$$\phi = \begin{bmatrix} \mathbf{b} \\ \mathbf{f}_c \end{bmatrix} \in \mathbb{R}^{2n_a} = \mathbb{R}^{24}, \quad (3.5)$$

其中 $\mathbf{b} = (b_1, \dots, b_{12})^\top$ 为黏滞阻尼向量， $\mathbf{f}_c = (f_{c,1}, \dots, f_{c,12})^\top$ 为库仑摩擦幅值向量。物理约束： $b_i \geq 0$, $f_{c,i} \geq 0$ 。

定义 3.1 是式 (2.17) 的一个具体实现版本。注入到式 (2.15) 后，关节驱动方程变为

$$\mathbf{M}(\mathbf{q}) \dot{\nu} + \mathbf{C}(\mathbf{q}, \nu) \nu + \mathbf{g}(\mathbf{q}) + \begin{bmatrix} \mathbf{0}_6 \\ \mathbf{b} \odot \dot{\boldsymbol{\theta}} + \mathbf{f}_c \odot \tanh(k \dot{\boldsymbol{\theta}}) \end{bmatrix} = \mathbf{S}^\top \boldsymbol{\tau} + \sum_i \mathbf{J}_{c,i}^\top \mathbf{f}_c^{(i)}, \quad (3.6)$$

其中 $\odot$ 表示逐元素乘积， $\mathbf{0}_6$ 占位浮动基座的 6 个非驱动自由度。式 (3.6) 即第 3 章辨识所基于的“带摩擦”动力学方程。

§3.4 经典辨识：线性回归与最小二乘

经典系统辨识方法基于一个观察：若动力学方程对 ϕ 线性，则可以写成 $\boldsymbol{\tau} = \mathbf{W}(\mathbf{q}, \dot{\mathbf{q}}, \ddot{\mathbf{q}}) \phi$ 的形式，从而由最小二乘直接闭式求解。

3.4.1 线性回归形式

式 (3.6) 中关节部分的方程关于 $(\mathbf{b}, \mathbf{f}_c)$ 是线性的——这并不是巧合，是有意将摩擦模型设计为参数线性。考虑关节 i ，将式 (3.6) 投影到该关节方向：

命题 3.1: 关节方向的辨识方程

对单关节 i ，第 t 时刻的运动方程关于 $(b_i, f_{c,i})$ 可写为线性形式

$$y_i(t) = \mathbf{w}_i(t)^\top \boldsymbol{\phi}_i, \quad \boldsymbol{\phi}_i = \begin{bmatrix} b_i \\ f_{c,i} \end{bmatrix} \in \mathbb{R}^2, \quad (3.7)$$

其中

$$y_i(t) = \tau_i^{\text{real}}(t) - [\mathbf{M}(\mathbf{q})\dot{\boldsymbol{\nu}} + \mathbf{C}\boldsymbol{\nu} + \mathbf{g}]_i^{\text{sim}}(t), \quad \mathbf{w}_i(t) = \begin{bmatrix} \dot{\theta}_i(t) \\ \tanh(k \dot{\theta}_i(t)) \end{bmatrix}.$$

y_i 为“实测力矩减去仿真出的非摩擦项”，即所谓**摩擦残差**； $\mathbf{w}_i$ 为该关节的回归向量。

命题 3.1 的工程意义：要从单关节数据辨识 $(b_i, f_{c,i})$ ，需要计算 $\mathbf{M}\dot{\boldsymbol{\nu}} + \mathbf{C}\boldsymbol{\nu} + \mathbf{g}$ 。这一计算需要：(1) 关节角加速度 $\ddot{\theta}_i$ （由数值差分关节角得到，引入噪声）；(2) 整机当前的 $\mathbf{M}, \mathbf{C}, \mathbf{g}$ （由第二章的工具算出）。因此经典方法的精度受限于 $\ddot{\theta}$ 估计精度。

3.4.2 多时刻数据的最小二乘

记某段实机数据有 T 个时刻 $t = 1, \dots, T$ 。对每个时刻每个关节叠加式 (3.7)，得到 T 个方程。考虑全部 n_a 个关节联合辨识，构造完整回归方程：

$$\mathbf{Y} = \mathbf{W}\boldsymbol{\phi}, \quad \mathbf{Y} \in \mathbb{R}^{Tn_a}, \quad \mathbf{W} \in \mathbb{R}^{Tn_a \times 2n_a}, \quad \boldsymbol{\phi} \in \mathbb{R}^{2n_a}. \quad (3.8)$$

命题 3.2: 最小二乘解

若 $\mathbf{W}^\top \mathbf{W}$ 可逆，式 (3.8) 的最小二乘解为

$$\hat{\boldsymbol{\phi}}_{\text{LS}} = (\mathbf{W}^\top \mathbf{W})^{-1} \mathbf{W}^\top \mathbf{Y}. \quad (3.9)$$

当数据噪声满足零均值高斯假设时， $\hat{\boldsymbol{\phi}}_{\text{LS}}$ 为无偏估计。

实际工程中常加 Tikhonov 正则化避免 $\mathbf{W}^\top \mathbf{W}$ 病态：

$$\hat{\boldsymbol{\phi}}_{\text{LS-reg}} = (\mathbf{W}^\top \mathbf{W} + \lambda \mathbf{I})^{-1} \mathbf{W}^\top \mathbf{Y},$$

$\lambda > 0$ 为正则化系数。

3.4.3 代码实现

数据生成 + $\mathbf{W}$ 矩阵装配的完整代码：

```
import numpy as np
import jax.numpy as jnp
from mujoco import mjx

# 假设已有实机记录 (q, dq, ddq, tau_real)，形状均为 (T, n_a) 或 (T, n_q)
# k 为 tanh 光滑参数
```

```

def assemble_W_and_Y(q, dq, ddq, tau_real, model, k=100.0):
    """装配经典辨识的回归矩阵 W 与残差向量 Y。"""
    T, n_a = dq.shape
    W = np.zeros((T * n_a, 2 * n_a))
    Y = np.zeros(T * n_a)
    for t in range(T):
        # 用 mjb 的 RNEA 算非摩擦项  $M\ddot{d}v + C*v + g$ 
        data = mjb.make_data(model).replace(qpos=q[t], qvel=dq[t])
        non_friction = mjb.rne(model, data, ddq[t]) # 含  $M, C, g$  项
        # 残差 = 实测力矩 - 非摩擦项 (取关节维度)
        Y[t*n_a:(t+1)*n_a] = tau_real[t] - non_friction[-n_a:]
        # 回归向量: 每关节对应  $(dq_i, \tanh(k*dq_i))$ 
        for i in range(n_a):
            row = t * n_a + i
            W[row, i] = dq[t, i] #  $b_i$  系数
            W[row, n_a + i] = np.tanh(k * dq[t, i]) #  $f_{c,i}$  系数
    return W, Y

```

最小二乘求解 + 正则化:

```

def least_squares_solve(W, Y, lam=1e-4):
    """正则化最小二乘求解 phi。"""
    n = W.shape[1]
    A = W.T @ W + lam * np.eye(n)
    b = W.T @ Y
    phi_hat = np.linalg.solve(A, b)
    b_hat = phi_hat[:12] # 前 12 个为  $b_i$ 
    fc_hat = phi_hat[12:] # 后 12 个为  $f_{c,i}$ 
    return b_hat, fc_hat

```

3.4.4 经典方法的三个工程局限

经典最小二乘有数学闭式解的优势，但在四足辨识中暴露出三个局限：

1. **W 矩阵的手工推导。** 命题 3.1 中 w_i 的具体形式依赖摩擦模型形式。换用 LuGre、Stribeck 等更复杂模型时，**W** 必须重新推导。这与“第一章 主定理”用同一引擎处理任意可微模型”的诉求相悖。
2. **$\ddot{\theta}$ 估计的噪声放大。** **Y** 含 $M\ddot{v}$ 项，依赖 $\ddot{\theta}$ 。实机仅测关节角， $\ddot{\theta}$ 由二阶差分得到，噪声功率谱被 ω^2 放大。这是表 3.1 中转子惯量 $I_{r,i}$ 辨识难度高的根本原因——它仅在 $\ddot{\theta}$ 项中出现。
3. **sgn 的硬切换处理。** 经典方法要求模型对参数线性。库仑摩擦的 $\text{sgn}(\dot{\theta}_i)$ 严格说不是 $f_{c,i}$ 的线性算子（在 $\dot{\theta} = 0$ 处导数不存在）。式 (3.4) 的 $\tanh$ 替换缓解了此问题，但本质上是把“不可微”问题塞回了模型——下节的可微方法把这一处理统一进自动微分框架。

这三个局限正是 第一章 主定理的可微方法所要解决的对象。第 3.6 节 给出对应的处理方式。

§3.5 持续激励与轨迹设计

辨识精度的上限不仅由算法决定，也由数据决定。本节简要讨论数据采集策略。

3.5.1 核心条件

命题 3.3: 持续激励的频域条件（直观陈述）

辨识 ϕ 中的某一参数，要求采集数据的轨迹在该参数所对应的动力学模式上有足够频谱能量。具体地， b_i 对应低频功率（与速度成正比）， $f_{c,i}$ 对应过零事件， $I_{r,i}$ 对应高频加速度成分。

命题 3.3 的严格频域形式涉及 $\mathbf{W}$ 的条件数与谱密度，详见 Ljung [9] 第 13 章。工程上的实操要点：

- 单一稳态步态（如纯 trot 在固定速度）数据贫乏：黏滞阻尼可辨，库仑摩擦勉强可辨，转子惯量基本不可辨。
- 多频正弦扫频（chirp）信号： $\theta_i^{\text{ref}}(t) = A \sin(\omega(t)t)$ ， $\omega(t)$ 从低到高线性变化，可同时激发各频段。
- 实际四足项目常用混合策略：trot 步态数据为主，叠加几次小幅 chirp 测试。

数据量经验值：xg 在 1 kHz 采样下，2–5 分钟数据足够辨识 $\{b_i, f_{c,i}\}$ ；辨识 $\{I_{r,i}\}$ 需 10 分钟以上含丰富激励的数据。

3.5.2 激励轨迹与 PE 条件

定量地，PE 条件等价于 $\mathbf{W}^\top \mathbf{W}$ 的条件数 $\kappa(\mathbf{W}^\top \mathbf{W})$ 不过大。工程上 $\kappa < 10^4$ 通常足以保证式 (3.9) 的数值稳定性。Project 2 的预备实验给学生定量观察 κ 与不同步态的关系——这是设计实机数据采集协议的标准做法。

§3.6 可微辨识：通过仿真器反向传播

第 3.4 节 末尾给出的三个工程局限——手推 $\mathbf{W}$ 、 $\ddot{\theta}$ 噪声放大、sgn 硬切换——都可以通过把仿真器视为可微算子统一解决。本节给出定理 1.1 (i) 的完整工程实现。

3.6.1 把仿真器看作 ϕ 的函数

定义 1.3 定义了可微物理仿真器 $\mathcal{F}$ 作为映射 $(\mathbf{q}_0, \dot{\mathbf{q}}_0, \boldsymbol{\tau}_{0:T-1}, \phi) \mapsto (\mathbf{q}_{1:T}, \dot{\mathbf{q}}_{1:T})$ 。在系统辨识场景下，反过来思考：给定实机的 $(\mathbf{q}_{0:T}, \dot{\mathbf{q}}_{0:T}, \boldsymbol{\tau}_{0:T}^{\text{real}})$ 全部已知，把仿真器视为 ϕ 的函数，问“哪个 ϕ 让仿真器最好地复现实测数据”。

具体地，定义**逆动力学仿真函数**

$$\tau_t^{\text{sim}}(\phi) = \text{InverseDynamics}_{\mathcal{F}}(\mathbf{q}_t, \dot{\mathbf{q}}_t, \dot{\mathbf{v}}_t; \phi), \quad (3.10)$$

即在仿真器中以参数 ϕ 配置摩擦项，输入实测的 $(\mathbf{q}_t, \dot{\mathbf{q}}_t, \dot{\mathbf{v}}_t)$ ，反算实现该状态-加速度组合所需的关节力矩。式 (3.10) 的具体计算就是 第二章 中的 RNEA 算法。

3.6.2 损失函数与梯度

定义 3.2: 可微辨识的损失函数

设实机记录数据集 $\mathcal{D} = \{(\mathbf{q}_t, \dot{\mathbf{q}}_t, \dot{\mathbf{v}}_t, \boldsymbol{\tau}_t^{\text{real}})\}_{t=1}^T$ 。可微辨识的损失函数定义为

$$\mathcal{L}(\phi) = \frac{1}{T} \sum_{t=1}^T \|\tau_t^{\text{sim}}(\phi) - \tau_t^{\text{real}}\|_2^2. \quad (3.11)$$

辨识结果定义为

$$\hat{\phi} = \underset{\phi \geq \mathbf{0}}{\operatorname{argmin}} \mathcal{L}(\phi). \quad (3.12)$$

约束 $\phi \geq \mathbf{0}$ 反映物理约束：阻尼与摩擦幅值非负。

由 定理 1.1 (i)， $\mathcal{L}$ 对 ϕ 的梯度可由自动微分给出：

$$\nabla_{\phi} \mathcal{L} = \frac{2}{T} \sum_{t=1}^T (\tau_t^{\text{sim}}(\phi) - \tau_t^{\text{real}})^{\top} \frac{\partial \tau_t^{\text{sim}}}{\partial \phi}. \quad (3.13)$$

关键之处在于 $\partial \tau_t^{\text{sim}} / \partial \phi$ ——它是仿真器内部计算图的反向传播结果，不需要手工推导。

注记 3.3: 相比经典方法的根本差别

命题 3.1 的经典方法要求把动力学方程关于 ϕ 显式重排为 $\boldsymbol{\tau} = \mathbf{W} \phi$ 的线性形式， $\mathbf{W}$ 必须由摩擦模型形式手工推导。可微方法把整个仿真器（含 RNEA 内部所有代数）视作一个可微函数， ∇_{ϕ} 由自动微分自动计算。换用 LuGre、Stribeck 或任意其他摩擦模型时，损失函数式 (3.11) 形式不变，仅需在式 (3.10) 中替换摩擦项的实现——一行代码。

3.6.3 Adam 优化与收敛诊断

式 (3.11) 是非凸函数（tanh 近似的存在让损失曲面有平台区），梯度下降容易陷入鞍点。工程实践用一阶动量优化器 Adam，学习率从 $\eta = 10^{-2}$ 起步，配合学习率衰减。

完整的可微辨识 pipeline 代码：

```
import jax
import jax.numpy as jnp
from mujoco import mjx
import optax

# 假设已有实机记录 (q_real, dq_real, ddv_real, tau_real), jnp.ndarray
```

```

# base_model 为 mjt.Model 实例 (base_model.opt.timestep 等已设置)
# k = 100.0 为 tanh 光滑参数

def inject_phi(model, phi):
    """把 phi = [b_1..b_12, fc_1..fc_12] 注入 mjt 模型。"""
    n_a = 12
    b = phi[:n_a]
    fc = phi[n_a:]
    # mjt 模型的 dof_damping 与 dof_frictionloss 对应黏滞与库仑摩擦
    new_damping = model.dof_damping.at[-n_a:].set(b)
    new_frictionloss = model.dof_frictionloss.at[-n_a:].set(fc)
    return model.replace(dof_damping=new_damping,
                        dof_frictionloss=new_frictionloss)

def loss_fn(phi):
    """单次损失计算，对 phi 可微。"""
    model_phi = inject_phi(base_model, phi)
    # vmap 在时间维并行：每个时刻独立的 RNEA
    def single_step(q_t, dq_t, ddd_t):
        data = mjt.make_data(model_phi).replace(qpos=q_t, qvel=dq_t)
        return mjt.rne(model_phi, data, ddd_t)
    tau_sim = jax.vmap(single_step)(q_real, dq_real, ddd_real)
    # 取关节维度（最后 n_a 维），与 tau_real 对齐
    return jnp.mean((tau_sim[:, -12:] - tau_real) ** 2)

grad_fn = jax.grad(loss_fn)

# Adam 优化循环
phi = jnp.concatenate([jnp.ones(12) * 0.05,  # b_i 初值 0.05 N·m·s/rad
                      jnp.ones(12) * 1.0])  # fc_i 初值 1.0 N·m
optimizer = optax.adam(learning_rate=1e-2)
opt_state = optimizer.init(phi)

losses = []
for step in range(2000):
    L = loss_fn(phi)
    g = grad_fn(phi)
    updates, opt_state = optimizer.update(g, opt_state)
    phi = optax.apply_updates(phi, updates)
    phi = jnp.maximum(phi, 0.0)  # 投影到非负锥（物理约束）
    losses.append(float(L))
    if step % 100 == 0:
        print(f"step {step}: loss = {L:.6f}")

```

收敛诊断的工程实践：

- **损失曲线.** 监控 $\mathcal{L}(\phi^{(k)})$ 随迭代 k 的下降。理想情况下 $\mathcal{L}$ 下降两到三个数量级后趋于平台。
- **梯度范数.** $\|\nabla \mathcal{L}\|$ 应单调下降至接近零。若长期不降，多为陷入鞍点，应增大学习率或重启

动。

- **参数轨迹.** 若已知合成数据真值 ϕ^* ，监控 $\|\hat{\phi}^{(k)} - \phi^*\|$ 。图 3.1 给出典型行为。




图 3.1: 典型收敛曲线 (示意)。经典最小二乘一次性给出闭式解 (单点); 可微方法迭代下降, 在 1500–2000 步后达到由数据噪声决定的精度极限。

3.6.4 经典 vs 可微方法对比

将两种方法的工程特性对比如下:

维度	经典最小二乘	可微梯度方法
求解形式	闭式解 式 (3.9)	迭代优化 (Adam / L-BFGS)
计算时间	一次矩阵求逆 (~ 秒)	数百次仿真 rollout (~ 分钟)
模型扩展	W 须重推	仅改一处仿真器代码
sgn 处理	数据避开 $\dot{\theta} = 0$ 区间	tanh 光滑或更复杂的可微近似
$\ddot{\theta}$ 依赖	强 (直接出现在 Y 中)	弱 (rollout 内部处理)
噪声鲁棒性	二阶差分放大噪声	优化器自带平滑
非线性参数	不支持 (限线性参数)	任意可微模型
代码长度	短 (~ 30 行)	中 (~ 50 行)
教学价值	经典理论的具体化	主定理 定理 1.1 (i) 的兑现

表 3.2: 经典最小二乘与可微梯度方法的对比

表 3.2 第三、第七行是工程上最有分量的两点: 经典方法在四足这类系统上每换一个摩擦模型就要重推 **W**, 而四足摩擦的精确建模本身就是一个开放的工程问题。可微方法允许工程师把模型形式作为可调超参, 而不是辨识管线的固定结构。

3.6.5 辨识误差分析

理想情况下 $\hat{\phi} \rightarrow \phi^*$ 。实际中 $\hat{\phi}$ 与 ϕ^* 的偏差由三个独立来源贡献：

- **数据噪声.** 实机传感器（编码器、力矩传感器或电流估算）含零均值噪声。最小二乘理论保证渐近无偏，但有限数据下方差非零。约 1%–3% 误差。
- **未建模动态.** 不在 ϕ 中的字段（如惯量张量的 CAD 偏差）以系统性残差进入辨识。约 2%–5% 误差。
- **tanh 近似偏差.** 式 (3.4) 的光滑化在 $|\theta| < 1/k$ 区间引入的偏差。约 1%–2%（仅影响 $\hat{\mathbf{f}}_c$ ）。

总体上，定义 3.1 中 24 维 ϕ 的辨识相对误差工程上达到 5%–10% 即为成功。Project 2 把基准设为 5%。

§3.7 完整 pipeline 与 Project 2 预告

3.7.1 xg 摩擦辨识完整 pipeline

将本章所有内容串成一条完整工程链路：

1. **数据采集.** 在 xg 上运行 trot 步态混合 chirp 激励，2–5 分钟，1 kHz 采样，记录 $(\mathbf{q}_t, \dot{\mathbf{q}}_t, \boldsymbol{\tau}_t)$ 。
2. **数据预处理.** 由 $\mathbf{q}_t$ 二阶差分得 $\dot{\mathbf{v}}_t$ ，配合低通滤波抑制噪声。
3. **选择辨识范围.** 依表 3.1 确定 ϕ 维度（基础 12 / 标准 24 / 进阶 36）。
4. **模型注入接口.** 实现 `inject_phi(model, phi)` 把 ϕ 写入仿真模型的对应字段。
5. **选择辨识算法.** 经典方法（式 (3.9)）作为快速 baseline；可微方法（式 (3.11)）作为主辨识器。
6. **优化执行.** Adam 学习率 10^{-2} ，1000–2000 步，监控 $\mathcal{L}$ 与 $\|\nabla \mathcal{L}\|$ 。
7. **结果验证.** 在独立的验证数据集上计算 $\mathcal{L}(\hat{\phi})$ 。若与训练损失同量级，辨识成功；若验证损失显著大于训练损失，说明过拟合，应增加数据或加正则化。
8. **部署.** 把 $\hat{\phi}$ 写回 `xg.urdf` 或 MJCF；后续章节的 RL 训练在含 $\hat{\phi}$ 的仿真器上进行。

3.7.2 Project 2：xg 摩擦辨识

任务. 给出一组合成的“实机”数据（在仿真器中以已知真值 ϕ^* 跑出的轨迹，加 1% 高斯噪声），辨识 $\hat{\phi}$ ，与 ϕ^* 比较精度。

分级要求.

- **基础（必做）.** 辨识 12 维 $\mathbf{b}$ （仅黏滞阻尼），相对误差 $\|\hat{\mathbf{b}} - \mathbf{b}^*\| / \|\mathbf{b}^*\| < 10\%$ 。
- **标准（推荐）.** 辨识 24 维 $(\mathbf{b}, \mathbf{f}_c)$ ，相对误差 $< 5\%$ 。

- **进阶 (stretch)** . 加上 $\mathbf{I}_r$, 36 维, 相对误差 $< 10\%$ 。

交付物.

1. Python 脚本, 包含数据加载、模型注入、loss 定义、Adam 训练循环、结果保存。
2. 三张图: 损失曲线、梯度范数曲线、 $\hat{\phi}$ 各分量与 ϕ^* 对比。
3. ≤ 4 页报告: 解释为什么选这个 ϕ 维度、tanh 光滑参数 k 的选择、收敛行为分析、与经典最小二乘 baseline 的精度/时间对比。

评分重点. 不在于”达到最低误差阈值”, 而在于: (1) 能否解释每一步的工程权衡; (2) 能否诊断收敛失败的原因; (3) 经典方法 baseline 的对比是否合理。

3.7.3 与第6章的衔接

定理 1.1 (i) 给出辨识 $\hat{\phi}$; 定理 1.1 (iii) 给出 RL 策略 $\pi_{\hat{\theta}}$ 。把两者结合的方式有两种:

- **先辨识, 再训练.** 用 $\hat{\phi}$ 替换 URDF 中的零值字段, 在新的仿真器上从头训练 $\pi_{\hat{\theta}}$ 。这是最干净的工作流, 第 4–5 章 RL 训练默认这样做。
- **摩擦前馈.** 在已训好的策略输出上叠加 $\hat{\mathbf{b}} \odot \dot{\boldsymbol{\theta}} + \hat{\mathbf{f}}_c \odot \text{sgn}(\dot{\boldsymbol{\theta}})$ 的前馈项。第 6 章 sim-to-real 详细讨论。

无论采取哪种方式, 本章辨识结果 $\hat{\phi}$ 都是后续工程的输入。

第3章习题

1. **(概念)** 用一句话说明: 为什么表 3.1 把质量 m_ℓ 列为”不辨识”, 把库仑摩擦 $f_{c,i}$ 列为”必须辨识”? 提示: 考虑 CAD 给出的精度 vs URDF 默认值。
2. **(推导)** 由式 (3.6) 出发, 对单关节 i 在静态平衡条件 $\boldsymbol{\nu} = \mathbf{0}, \dot{\boldsymbol{\nu}} = \mathbf{0}, \dot{\theta}_i \neq 0$ (缓慢匀速) 下, 验证 $\tau_i^{\text{real}} = b_i \dot{\theta}_i + f_{c,i} \text{sgn}(\dot{\theta}_i) + g_i(\mathbf{q})$ 。在此条件下, 命题 3.1 的 $\mathbf{Y}$ 与 $\mathbf{w}_i$ 简化为何形式?
3. **(定量)** 取 $k = 100$, 比较 $\tanh(k \dot{\theta})$ 与 $\text{sgn}(\dot{\theta})$ 在 $\dot{\theta} \in \{0.001, 0.01, 0.1, 1.0\}$ rad/s 下的相对误差。从该计算说明为什么注记 3.2 中” $|\dot{\theta}| > 1/k$ 区间偏差小于 1%”。
4. **(设计)** 设计一段 chirp 激励轨迹的伪代码: $\theta_i^{\text{ref}}(t) = A \sin(\omega(t) t)$, ω 从 0.5 Hz 线性增到 10 Hz, 持续 30 秒, 幅值 $A = 0.3$ rad。在何种构型下执行这段轨迹? 讨论: 执行时其他关节是否应保持静止?
5. **(推导)** 设 $\phi^* = (b^*, f_c^*)$ 为真实参数。证明: 在数据噪声为 $\mathcal{N}(0, \sigma^2)$ 高斯白噪声、采样数据量 $T \rightarrow \infty$ 极限下, 式 (3.9) 给出的 $\hat{\phi}_{\text{LS}}$ 是 ϕ^* 的无偏估计。提示: 用式 (3.8) 的概率展开。

6. **(深入思考)** 表 3.2 指出可微方法在 $\ddot{\theta}$ 依赖上“弱”。请解释这一现象的根本原因：为什么经典方法的 $\mathbf{Y}$ 直接含 $\ddot{\theta}$ ，而可微方法的式 (3.11) 似乎避开了？提示：考察可微方法实际计算 τ^{sim} 时仿真器内部如何使用 $\dot{\nu}$ 。
7. **(编程预备)** 编写一段 Python 脚本（约 30 行），生成合成的 xg 摩擦辨识数据集。流程：(a) 设定真值 ϕ^* ($b^* = 0.05, f_c^* = 1.0$)；(b) 在含 ϕ^* 的 mjx 模型上运行 trot 步态 60 秒；(c) 加 1% 高斯噪声；(d) 保存 $(\mathbf{q}, \dot{\mathbf{q}}, \dot{\nu}, \tau)$ 数据。本题是 Project 2 的预备。

参考文献

- [1] Di Carlo, J., Wensing, P. M., Katz, B., Bledt, G., & Kim, S. (2018). *Dynamic locomotion in the MIT Cheetah 3 through convex model-predictive control*. IROS 2018.
- [2] Bellicoso, C. D., Jenelten, F., Gehring, C., & Hutter, M. (2018). *Dynamic locomotion through online nonlinear motion optimization for quadrupedal robots*. IEEE RAL, 3(3).
- [3] Kumar, A., Fu, Z., Pathak, D., & Malik, J. (2021). *RMA: Rapid Motor Adaptation for legged robots*. RSS 2021.
- [4] Rudin, N., Hoeller, D., Reist, P., & Hutter, M. (2022). *Learning to walk in minutes using massively parallel deep reinforcement learning*. CoRL 2021.
- [5] Rawlings, J. B., Mayne, D. Q., & Diehl, M. M. (2017). *Model Predictive Control: Theory, Computation, and Design*. Nob Hill Publishing.
- [6] Featherstone, R. (2008). *Rigid Body Dynamics Algorithms*. Springer.
- [7] Murray, R. M., Li, Z., & Sastry, S. S. (2017). *A Mathematical Introduction to Robotic Manipulation*. CRC Press.
- [8] Lynch, K. M., & Park, F. C. (2017). *Modern Robotics: Mechanics, Planning, and Control*. Cambridge University Press.
- [9] Ljung, L. (1999). *System Identification: Theory for the User* (2nd ed.). Prentice Hall.
- [10] Kingma, D. P., & Ba, J. (2015). *Adam: A method for stochastic optimization*. ICLR 2015.
- [11] De Groote, F., et al. (2008). *Identification of dynamic friction in joints with harmonic drives*. ICRA 2008.
- [12] Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). *Proximal Policy Optimization Algorithms*. arXiv:1707.06347.
- [13] Schulman, J., Moritz, P., Levine, S., Jordan, M., & Abbeel, P. (2016). *High-Dimensional Continuous Control Using Generalized Advantage Estimation*. ICLR 2016.
- [14] Makoviychuk, V., et al. (2021). *Isaac Gym: High Performance GPU-Based Physics Simulation For Robot Learning*. NeurIPS Datasets and Benchmarks 2021.
- [15] Andrychowicz, M., et al. (2021). *What Matters In On-Policy Reinforcement Learning? A Large-Scale Empirical Study*. ICLR 2021.
- [16] Xu, J., Makoviychuk, V., Narang, Y., Ramos, F., Matusik, W., Garg, A., & Macklin, M. (2022). *Accelerated Policy Learning with Parallel Differentiable Simulation*. ICLR 2022.
- [17] Mora, M. A. Z., Peychev, M., Ha, S., Vechev, M., & Coros, S. (2021). *PODS: Policy Optimization via Differentiable Simulation*. ICML 2021.

- [18] Tobin, J., Fong, R., Ray, A., Schneider, J., Zaremba, W., & Abbeel, P. (2017). *Domain Randomization for Transferring Deep Neural Networks from Simulation to the Real World*. IROS 2017.
- [19] Peng, X. B., Andrychowicz, M., Zaremba, W., & Abbeel, P. (2018). *Sim-to-Real Transfer of Robotic Control with Dynamics Randomization*. ICRA 2018.
- [20] Lee, J., Hwangbo, J., Wellhausen, L., Koltun, V., & Hutter, M. (2020). *Learning Quadrupedal Locomotion over Challenging Terrain*. Science Robotics 5(47).
- [21] Kumar, A., Fu, Z., Pathak, D., & Malik, J. (2021). *RMA: Rapid Motor Adaptation for legged robots*. RSS 2021. (Phase 2 在线适应详细描述)
- [22] Tan, J., et al. (2018). *Sim-to-Real: Learning Agile Locomotion For Quadruped Robots*. RSS 2018.
- [23] Hwangbo, J., Lee, J., Dosovitskiy, A., Bellicoso, D., Tsounis, V., Koltun, V., & Hutter, M. (2019). *Learning agile and dynamic motor skills for legged robots*. Science Robotics 4(26).
- [24] Ljung, L. (1999). *System Identification: Theory for the User* (2nd ed.). Prentice Hall. (Chapter 11: Recursive estimation)